

K-ICS 규제 환경 하 보험사의 동적 환위험 헤지 의사결정 시스템

시장 국면 인식(HMM) 및 강화학습(PPO) 기반 자본 효율성 최적화 전략 구현 및 실증
팀명: 저녁은 뉴욕에서

초록

본 연구는 신지급여력제도(K-ICS)¹ 환경에서 보험사의 자본 안정성 확보와 환헤지 효율성을 동시에 달성하기 위한 데이터 기반의 동적 환헤지 프레임워크를 제안한다. 특히 한·미 금리차 역전으로 인해 NDF 스왑포인트가 음(-)의 영역에 머물고 있는 2026년 현재의 특수한 시장 환경을 반영하여, 기존의 100% 환헤지 관행이 가용자본(AC)을 직접적으로 잠식하는 구조적 한계를 심도 있게 분석한다. 이를 해결하기 위해 본 논문은 Hidden Markov Model(HMM)을 활용하여 비관측 시장 국면을 정의하고, 복잡한 K-ICS 자본비율 산출 과정을 고속화하는 근사 대리 모델(Surrogate Model)을 연계하여 강화학습(PPO)² 최적화 환경을 구축하였다. 제안된 프레임워크는 현행 표준모형 하에서는 비용 최소화를 통해 분자 항목인 가용자본을 보전하고, 향후 시장위험 내부모형 도입 시에는 자산 간 동적 상관관계를 반영하여 분모 항목인 요구자본(SCR)을 최적화하는 단계적(Phased) 대응 전략을 제시한다. 실증 분석 결과, 본 모델은 기존 전략 대비 '자본 효율성 수정 샵프지수'를 크게 개선하였으며, AI 위험관리 프레임워크(AI RMF)³에 부합하는 다단계 Contingency Plan과 거버넌스 설계를 통해 극단적 변동성 상황에서도 강력한 규제 복원력을 입증하였다. 이는 향후 보험사의 AI 기반 위험관리 체계 고도화에 실질적인 기여를 할 것으로 기대된다.

Keywords: 강화학습, 동적 헤지, 설명 가능 AI, 시장 국면 인식, 포트폴리오 최적화, Contingency Plan, Hidden Markov Model, K-ICS, Natural Hedge, PPO

1. 서론

1.1 연구 배경 및 동기

보험회사의 지급여력(Solvency) 관리는 보험계약자 보호 및 금융 시스템의 건전성 유지를 위한 핵심 지표다. 2023년 한국에 도입된 신지급여력제도(K-ICS)⁴는 자산과 부채를 시가로 평가하여 보험사의 실질적인 리스크 감내 능력을 측정하며, 자본비율 100% 이상 유지를 법적 의무로 규정하고 있다. 특히 해외 투자 비중이 높은 국내 보험 산업의 특성상, 환율 변동은 외화 자산의 가치와 가용자본에 직접적인

¹ 금융감독원(2022), 「보험업권 신지급여력제도(K-ICS) 해설서」 및 관련 규정 시행 세칙.

² Schulman, J. et al. (2017), "Proximal Policy Optimization Algorithms", arXiv:1707.06347.

³ 금융위원회(2026), 「금융분야 AI 위험관리 프레임워크(AI RMF)」.

⁴ 금융감독원(2022), 「보험업권 신지급여력제도(K-ICS) 해설서」.

영향을 미치는 주요 변동성 요인이다. 이에 대응하여 대다수 보험사는 외환 노출액 전체를 헤지하는 100% 헤지 관행을 유지해 왔으나, 이는 시장 변화에 유연하게 대응하지 못하는 정적 의사결정이라는 한계를 지닌다. 특히 2026년 현재, 한·미 금리차 역전 지속으로 인해 NDF 스왑포인트가 -1.3원 수준의 음(-)의 영역에 머물고 있는 환경은 보험사에게 수익률 저하 및 자본 효율성 압박 요인으로 작용하고 있다. 실제로 K-ICS 리스크 산출 시 리스크 간 상관관계를 활용한 분산효과를 적용할 경우, 시장위험액은 개별 위험액의 단순 합계 대비 약 32% 감소한다(노희준·조영현/보험연구원, 2024)⁵. 이는 통합 리스크 관리가 자본 관리 효율성에 결정적인 영향을 미침을 시사한다. 그럼에도 불구하고 현행 K-ICS 표준모형은 주식과 외환 리스크 간의 상관계수를 -0.25로 고정하여 운영하고 있어, 실제 시장에서 관측되는 동적인 상관관계 및 자연 헤지(Natural Hedge) 효과를 산식에 직접 반영하기 어렵게 만든다. 이러한 규제적 경직성 하에서 지속되고 있는 일률적인 100% 헤지는 상당한 수준의 스왑포인트 비용을 발생시켜 가용자본(AC)을 직접적으로 훼손하는 구조적 비효율을 초래한다. 최근 국내 보험업계의 내부모형(Internal Model) 신청 사례가 전무한 현실을 고려할 때, 보험사는 규제 준수와 경제적 효율성 사이의 상충 관계를 해결할 새로운 대안이 필요하다. 이에 본 연구는 단순히 가격을 예측하는 기존 AI 방식에서 벗어나, 시장 국면(Regime)을 식별하고 그에 따른 최적 정책을 도출하는 동적 환헤지 시스템을 제안한다. 구체적인 연구 동기는 다음과 같다. 첫째, 자본 효율성 측면에서의 방법론적 개선이다. 기존 표준모형 하의 일률적인 헤지 전략은 음(-)의 스왑포인트 국면에서 발생하는 과도한 거래 비용을 간과하는 경향이 있다. 본 연구는 국면별 최적 헤지 비중을 산출하는 알고리즘을 통해 불필요한 비용 지출을 최소화하고, 규제 산식 내 가용자본(AC)을 실질적으로 보전할 수 있는 최적화 모델을 제시한다. 둘째, 내부모형 도입에 대비한 리스크 관리 인프라의 정교화이다. 2026년 시행되는 내부모형 제도는 자본 산출의 유연성을 부여하는 동시에 높은 수준의 리스크 측정 정밀도를 요구한다. 본 시스템은 시장 변수 간의 동적 상관관계를 포착하여 요구자본(SCR) 산출에 직접 반영함으로써, 분모 항목인 리스크 측정치의 정확도를 높이고 자본 활용의 효율성을 극대화하는 기틀을 마련한다. 셋째, 규제 준수와 AI 거버넌스의 통합적 구현이다. 금융 시장의 비정형적 위기 상황에 대응하기 위해, 강화학습 모델의 자율성과 리스크 관리자의 통제권이 결합된 'Human-in-the-loop' 구조를 설계하였다. 이는 2026년 시행된 '금융분야 AI RMF(위험관리 프레임워크)'의 핵심 지침을 준수하는 동시에, 다중 안전 장치를 통해 극단적 시장 상황에서도 규제 하한선을 안정적으로 유지하는 실천적 방안을 제시한다. 본 연구는 현행 표준모형 체제에서의 실질적 수익성 방어와 미래 내부모형 체제에서의 자본 최적화라는 단계적 효익을 실증적으로 입증하고자 한다.

1.2 연구 목적

본 연구의 궁극적인 목적은 K-ICS 규제 환경 하에서 보험사의 자본 변동성을 최소화하고 환헤지의 경제적 효율성을 극대화하는 인공지능 기반의 의사결정 체계를 구축하는 것이며, 세부적인 목표는 다음과 같다. 첫째, K-ICS 하에서의 리스크 분산 효과를 실증한다. 주식 및 외환 리스크 간의 상관관계를 고려한 요구자본(SCR) 산출식을 바탕으로, 전액 헤지 관행이 포트폴리오의 자연 헤지(Natural Hedge) 효과를 저해함을 입증한다. 이를 통해 부분 헤지 전략이 자본비용 유지와 헤지 비용 절감을 동시에 달성할 수 있는 이론적·실증적 근거를 제시한다. 둘째, 시장 국면 인식을 결합한 지능형 동적 헤지 시스템을 설계한다. 비관측 시장 상태를 추론하는 Hidden Markov Model(HMM)과 복잡한 환경에서 최적 정책을 도출하는 근위 정책 최적화(PPO) 알고리즘을 통합한다. 특히 방대한 연산량이 요구되는 K-ICS 자본비용 산출 과정을 대리 모델(Surrogate Model)로 고속화하여 강화학습 에이전트의 효율적인 학습 환경을 구현한다. 셋째, 규제 제약 조건 하에서의 다목적 최적화를 달성한다. K-ICS 자본비용 100% 이상 유지라는 엄격한 규제 제약을 만족함과 동시에, 헤지 비용과 자본비용의 변동성을 최소화하는 최적

⁵ 노희준·조영현(2024), "K-ICS 도입에 따른 보험회사 리스크 관리 변화와 시사점", 보험연구원(KIRI).

정책을 학습한다. 또한 이를 다양한 시장 시나리오 및 스트레스 테스트를 통해 검증함으로써 모델의 강건성을 확인한다. 넷째, AI 모델의 신뢰성 및 실무적 수용성을 확보한다. SHAP(SHapley Additive exPlanations) 기법⁶을 활용하여 모델의 헤지 비중 결정 논리를 시각화함으로써 '블랙박스' 문제를 해소한다. 더불어 극단적 시장 변동성 상황에서 시스템이 보수적 관리 모드로 즉각 전환되도록 설계된 Contingency Plan를 통해 금융 실무 현장에서 요구되는 안전 장치를 제시한다.

1.3 논문 구성

본 논문은 총 6 장으로 구성되어 있으며, 각 장의 주요 내용은 다음과 같다. 2 장에서는 K-ICS 규제 환경, 환위험 관리 전략, 그리고 국면 인식 및 강화학습의 금융권 적용 사례에 관한 이론적 배경과 선행 연구를 고찰한다. 3 장에서는 기존 보험사 환헤지 관행의 구조적 한계를 분석하고, K-ICS 산식 하에서 주식과 외환 자산 간의 상관관계에 따른 자본 분산 효과를 수리적으로 정의하여 연구의 토대를 마련한다. 4 장에서는 본 연구의 핵심인 동적 환헤지 시스템의 아키텍처를 상술한다. HMM을 이용한 국면 분류 알고리즘부터 PPO 기반의 의사결정 체계, 연산 효율화를 위한 Surrogate 모델, 그리고 실무적 안전성을 담보하는 Contingency Plan와 XAI 모듈의 설계 과정을 상세히 기술한다. 5 장에서는 실증 분석을 위해 구축된 데이터셋과 실험 환경을 설명하고, 12 종의 스트레스 시나리오 및 역사적 금융 위기 국면에서의 성과 분석(Regime-specific Efficient Frontier) 결과를 제시한다. 이를 통해 제안 모델의 강건성과 자본 효율성을 검증한다. 마지막으로 6 장에서는 연구 결과를 요약하고, 본 연구가 지니는 학술적·실무적 시사점과 한계점, 그리고 향후 연구 방향을 제시하며 결론을 맺는다.

2. 선행연구

2.1 K-ICS 및 보험 자본규제

2.2 환위험 헤지와 자연 헤지(Natural Hedge)의 역설

전통적인 외환 리스크 관리 문헌에서는 선물환, 통화 스왑(CRS) 등을 활용하여 포트폴리오의 외환 노출액을 최소화하는 '최소 분산 헤지(Minimum Variance Hedge)' 비율 산출에 집중해 왔다. 그러나 보험사와 같이 장기 부채를 보유하고 글로벌 자산 배분을 수행하는 기관 투자자의 경우, 개별 리스크의 최소화가 반드시 전체 시스템의 최적화로 이어지지 않는다. 특히 글로벌 금융 시장에서 관측되는 주식 수익률과 환율 변동성 간의 음의 상관관계는 강력한 자연 헤지(Natural Hedge) 수단으로 작용한다. 예를 들어, 시장 위기 상황에서 주식 자산 가치가 하락할 때 달러화 가치가 상승(안전자산 선호)하면, 환노출 포지션은 주식 부문의 손실을 환차익으로 상쇄하여 전체 가용자본의 급격한 하락을 방어한다. K-ICS 규제 체계 내에서 이러한 상관관계는 요구자본(SCR) 산출 시 리스크 간 분산 효과로 반영된다. 만약 보험사가 관행적으로 100% 전액 헤지를 수행할 경우, 이러한 통계적 분산 이익을 인위적으로 제거하게 되어 오히려 통합 SCR 관점에서는 불필요하게 높은 자본을 적립해야 하는 '헤지의 역설'이 발생한다. 본 연구는 이러한 구조적 비효율을 해결하기 위해, 시장 국면에 따라 변화하는 상관관계수의 동학을 분석하고, '단순 리스크 회피'가 아닌 '자본 효율성 극대화'를 위한 최적 동적 헤지 비율을 실증적으로 도출하고자 한다.

⁶ Lundberg, S. M., & Lee, S. I. (2017), "A Unified Approach to Interpreting Model Predictions", NeurIPS.

2.3 시장 국면(Regime) 인식과 Hidden Markov Model

금융 시계열 데이터는 경제 환경이나 정책 변화에 따라 통계적 특성이 급격히 변하는 비정상성(Non-stationarity)을 띤다. 선행 연구(Hamilton, 1989)는 시장이 단일한 정규분포를 따르지 않으며, 관측되지 않은 잠재 상태에 따라 서로 다른 모수(Parameter)를 가진 국면들이 전환된다는 '국면 전환 모델'의 유효성을 입증해 왔다. 특히 Hidden Markov Model(HMM)은 현재의 시장 국면을 직접 관측할 수는 없으나, 수익률이나 변동성 같은 관측 가능한 변수들을 통해 상태 전이 확률을 추론할 수 있다는 점에서 금융 위기 감지 및 자산 배분 연구에 널리 활용되어 왔다. 기존 문헌들은 주로 거시경제 지표나 시장 변동성 지표를 관측치로 활용하여 국면을 정의해 왔으며, 이는 단순한 시계열 예측 모델이 포착하지 못하는 시장의 구조적 변화를 식별하는 데 강점을 가진다. 본 연구는 이러한 선행 연구를 바탕으로, 보험사의 특수한 규제 환경(K-ICS)을 반영할 수 있는 민감도 지표와 자산 간 상관관계 동학을 관측 변수에 통합함으로써, 리스크 관리에 최적화된 국면 인식 체계를 구축하고자 한다. 이는 기존의 정적 리스크 관리 체계를 '국면 의존적 동적 대응 체계'로 고도화하기 위한 이론적 기틀이 된다.

2.4 강화학습 기반 금융 의사결정과 안전성 연구

강화학습(RL)은 에이전트가 환경과의 상호작용을 통해 누적 보상을 극대화하는 정책을 학습한다는 점에서, 동적 포트폴리오 최적화 및 리스크 관리 분야의 핵심 기술로 주목받고 있다. 특히 Proximal Policy Optimization(PPO) 알고리즘은 정책 업데이트 범위를 제한함으로써 금융 데이터와 같이 노이즈가 강한 환경에서도 안정적인 수렴 성능을 보여 다수의 자산 배분 연구에서 그 유효성이 입증되었다. 그러나 전통적인 강화학습 모델은 보상 함수 극대화 과정에서 예상치 못한 극단적 행동을 수행할 위험이 있으며, 이는 엄격한 지급여력 비율 준수가 요구되는 보험 산업에 적용하기에는 한계가 있다. 이러한 '블랙박스' 알고리즘의 불확실성을 제어하기 위해, 최근 학계에서는 정책 결정 과정에 하드 제약을 부여하는 안전 강화학습 또는 제약 조건부 강화학습(Constrained RL) 연구가 활발히 진행되고 있다. 본 연구는 이러한 흐름을 확장하여, PPO 에이전트가 탐색하는 정책 공간에 규제 준수 가이드라인을 강제하는 'Contingency Plan'을 설계한다. 이는 강화학습의 유연한 의사결정 능력과 전통적인 리스크 관리의 보수적 안정성을 통합하는 접근법으로, 규제 위반에 대한 페널티 부여를 넘어 실무적인 안전 임계치를 실시간으로 적용한다는 점에서 기존 연구와 차별화된다.

2.5 Surrogate 모델과 설명 가능 AI 연구

K-ICS 하에서의 지급여력비율 산출은 수만 개의 시나리오를 바탕으로 한 대규모 연산을 수반하며, 이는 실시간 의사결정을 지원해야 하는 강화학습의 학습 환경 구축에 있어 큰 연산 병목을 야기한다. 선행 연구에서는 이러한 고비용 수리 모델을 모사하기 위해 심층 신경망(DNN) 기반의 대리 모델을 구축하여, 정밀도를 유지하면서 연산 속도를 크게 개선하는 방법론을 제시해 왔다. 특히 리스크 관리의 핵심인 꼬리 위험(Tail Risk) 구간에서의 정합성을 확보하기 위해 퀀타일 회귀(Quantile Regression) 등의 기법을 결합하여 근사 오차를 최소화하는 연구가 이어지고 있다. 한편, 인공지능 모델의 금융권 도입에 있어 가장 큰 장애물 중 하나는 결과 도출 과정의 투명성 부재, 즉 '블랙박스' 문제다. 최근에는 SHAP(Shapley Additive exPlanations)과 같은 게임 이론 기반의 설명 가능 AI(Explainable AI, XAI) 기법을 통해 각 입력 변수가 최종 의사결정에 미치는 기여도를 정량적으로 분석하려는 시도가 활발하다. 이는 모델의 예측 결과를 사후적으로 설명할 뿐만 아니라, 규제 당국이 요구하는 모델의 신뢰성 및 안전성 검증을 위한 핵심적인 도구로 활용되고 있다.

3. 문제 정의

3.1 K-ICS 규제와 환위험

K-ICS 체제 하에서 보험사의 지급여력비율(β)은 가용자본(AC)과 요구자본(SCR)의 비로 정의되며, 규제 당국은 이를 100% 이상으로 유지할 것을 권고한다. 이때 환율 변동(ΔFX)은 분자와 분모에 상이한 메커니즘으로 영향을 미친다. 첫째, 분자인 가용자본(AC) 측면에서 외화 순자산 노출액(NFA)에 대해 환헤지 비율(h)을 적용할 경우, 환율 변동에 따른 자본의 변화량(ΔAC)은 다음과 같다. 여기서 $c(h)$ 는 헤지 비율 h 에 따라 발생하는 스왑포인트 등의 거래 비용을 의미한다. 둘째, 분모인 SCR 측면에서는 외환 리스크뿐만 아니라 주식 리스크 등 타 리스크와의 상관관계(ρ)에 의해 통합 요구자본이 결정된다. 관행적인 전액 헤지($h=1$)는 환율 변동에 의한 가용자본의 민감도를 0에 가깝게 통제하여 단기적인 규제 준수 가시성을 확보해 준다. 그러나 이는 $\rho < 0$ 일 때 기대할 수 있는 주식-환율 간 분산 효과를 인위적으로 제거하며, 고정적인 헤지 비용을 발생시켜 장기적인 자본 효율성을 저해하는 결과를 초래한다. 따라서 본 연구는 규제 하한선($\beta \geq 100\%$)이라는 제약 조건 하에서 비용과 변동성을 최소화하는 최적의 헤지 비율(h)을 도출하는 것을 문제의 핵심으로 정의한다.

3.2 기존 환헤지 의사결정 체계의 한계점

보험 실무 및 선행 연구에서 활용되는 기존의 환헤지 전략들은 변화하는 시장 국면을 적절히 반영하지 못하는 정적구조를 지니며, 주요 한계점은 다음과 같다. 첫째, 100% 전략의 경직성이다. 이는 규제 준수 측면에서 가장 보수적이고 안정적인 대안으로 간주되나, 시장 국면과 무관하게 고정적인 스왑포인트 비용을 지출하게 한다. 특히 주식과 외환 간의 음의 상관관계가 강해지는 위기 국면에서도 환익에 의한 자본 방어 기회를 원천적으로 차단해 자본 효율성을 깎는 기회비용을 남긴다. 둘째, 고정 비율 헤지(예: 80% Fixed)의 하위 최적성이다. 특정 고정 비율을 유지하는 방식은 전액 헤지 대비 비용은 일부 절감할 수 있으나, 여전히 시장 변동성에 대한 능동적 대응이 불가능하다. 이는 자산 배분의 '모수 경직성' 문제를 야기하며, 예상치 못한 환율 급락기에 자본비율(β)이 규제 하한선을 하회할 위험에 노출된다. 셋째, 휴리스틱 기반 규칙(Rule-based) 전략의 불안정성이다. 특정 지표(예: VIX)의 임계치에 따라 헤지 비율을 조정하는 방식은 설계가 용이하나, 임계값 근처에서 의사결정의 불연속성이 발생한다. 이로 인해 불필요한 리밸런싱 비용이 발생하거나, 국면 전환의 전조 현상을 선제적으로 포착하지 못하는 지연 반응의 한계를 지닌다. 결론적으로, 기존 전략들은 시장의 비정상성(Non-stationarity)을 명시적으로 고려하지 않는다는 공통된 한계를 지닌다. 본 연구는 이러한 '정적 의사결정의 패러다임'을 '국면 인식 기반의 동적 최적화' 체계로 전환하여, 규제 준수와 비용 효율성이라는 상충하는 목표를 동시에 달성하고자 한다.

3.3 K-ICS 하의 상관관계 분산 효과와 자연 헤지(Natural Hedge)의 정량화

K-ICS의 요구자본(SCR)은 개별 리스크의 단순 합산이 아닌, 리스크 간 상관관계를 고려한 분산 기법을 통해 산출된다. 주식 리스크(SCR_e)와 외환 리스크(SCR_{fx}) 간의 통합 SCR은 다음과 같은 상관관계 행렬 기반의 산식으로 정의된다. 이때 h 는 헤지 비율을 적용한 후의 외환 리스크 노출액을 의미하며, ρ 는 두 자산 간의 상관계수다. 위 식에서 일 때, 외환 노출액은 주식 리스크를 상쇄하는 자연 헤지(Natural Hedge) 역할을 수행한다. 본 연구는 약 20년(5,292 거래일)의 시장 데이터를 바탕으로 상관계수 변화에

따른 최적 헤지 비율 및 SCR 절감 효과를 분석하였다. 실증 분석 결과, 주식과 환율 간의 음의 상관관계가 강해질수록 전액 헤지($h=1$)보다 부분 헤지 또는 미헤지 전략이 자본 효율성 측면에서 우월함이 입증되었다.

Table 1. 상관계수 변화에 따른 자본 절감률 비교

상관계수(ρ)	최적 헤지 비율	SCR(최적 헤지)	SCR(100% 헤지)	자본 절감률(%)
-0.6	0%	0.1190	0.1429	10.38%
-0.4	0%	0.1042	0.1250	5.98%
-0.2	10%	0.0926	0.1111	1.82%

* 주: 자본 절감률은 전액 헤지(100%) 대비 최적 헤지 시 요구자본 감소폭을 의미함.




Figure 1. 상관계수 변화에 따른 자본 절감 효과

* 주: 자본 절감률은 전액 헤지(100%) 대비 최적 헤지 시 요구자본 감소폭을 의미함. 실증 데이터에 따르면, 상관관계가 -0.6 수준으로 강화되는 국면에서는 헤지를 수행하지 않을 때($h=0$) 자본 요구량이 전액 헤지 대비 약 10.38% 감소하는 것으로 나타났다. 이는 단순히 헤지 비용을 아끼는 것을 넘어, K-ICS 규제 하에서 위험량 자체가 줄어드는 이중의 이득을 얻을 수 있음을 시사한다. 따라서 시장 국면을 실시간으로 포착하여 상관계수의 변화를 인식하는 동적 헤지 시스템의 구축은 보험사 자본 관리의 핵심 경쟁력이 된다.

4. 시스템 방법론

4.1 시스템 설계 개요

본 연구에서 제안하는 시스템은 금융 시장의 비정상성(Non-stationarity)을 전제로 하여, 가격 예측의 불확실성을 '국면 인식 기반의 정책 최적화'를 통해 극복하도록 설계되었다. 특히 보험사의 특수성인 K-ICS 규제 준수를 최우선 가치로 설정하며, 강화학습의 탐색(Exploration) 과정에서 발생할 수 있는 리스크를 다중 방어 체계(Contingency Plan)를 통해 통제하는 '신뢰할 수 있는 AI(Trustworthy AI)' 아키텍처를 지향한다.

4.2 시스템 아키텍처

본 시스템은 데이터 입력부터 최종 헤지 신호 출력까지 총 5 단계의 유기적인 모듈로 구성된다:




Figure 2. 시스템 아키텍처

우선 데이터 입력 단계에서는 VIX, FX 시계열, 주식-환율 간 60 일 이동 상관계수 및 한·미 금리차 등 다변량 시계열 데이터를 수집하여 관측 공간의 기초 자료를 생성한다. 이렇게 수집된 기초 데이터는 국면 인식 모듈로 전달되며, 여기서 은닉 마코프 모델(HMM)을 통해 현재 시장의 잠재적 상태를 추론하고 데이터를 추상화하는 과정을 거친다. 추론된 국면 정보와 실시간 K-ICS 자본비율 데이터는 의사결정 엔진인 PPO 에이전트의 입력값으로 활용된다. 에이전트는 해당 정보를 바탕으로 비용과 리스크가 최적화된 헤지 비율 조정값을 도출한다. 하지만 AI 모델의 출력이 곧바로 실행되는 것은 아니며, 이후 단계인 안전 검증 모듈에서 해당 전략이 규제 가이드라인을 준수하는지 다단계로 검증받게 된다. 예를 들어 자본비율이 일정 수준 이하로 하락할 경우 강제로 헤지 비율을 상향하거나 손절을 단행하는 등 단계별 비상 계획이 작동한다. 최종적으로 이러한 검증을 모두 통과한 데이터만이 출력층을 통해 실제 운용 프로세스에 적용 가능한 최종 헤지 신호로 생성된다.

4.3 시장 국면 인식 모델(HMM)

금융 시계열의 구조적 변화를 식별하기 위해 3 개의 은닉 상태를 가진 HMM 을 활용한다.




Figure 3. HMM 아키텍처

4.3.1 관측 변수 정의

강화학습 에이전트의 상태 공간을 구성하는 관측 변수는 시장의 절대적 변동성, 변화 속도, 가격의 균형 이탈 정도, 그리고 거시 경제적 압력을 포괄할 수 있도록 설계하였다. 각 변수는 에이전트가 현재 시장 국면을 판단하고 최적의 헤지 비중을 결정하는 데 필요한 정량적 근거를 제공한다. 우선 시장의 절대적인 변동성 수준과 그 확산 속도를 포착하기 위해 VIX 지수를 활용한다. 지수 그 자체인 VIX는 시장에 내재된 절대적인 공포 수준을 나타내며, 이와 함께 다음과 같이 정의되는 VIX 변화율(ΔVIX)을 산출하여 변동성의 증가 또는 완화 속도를 파악한다. *t는 시점 다음으로 외환 시장의 수급 불균형과 원화의 상대적 가치 평가를 위해 환율 이동평균 괴리율(FX_Div)을 도입한다. 원/달러 환율(FX)과 중장기 이동평균(MA)을 이용하여 산출되는 이 지표는, 현재 환율이 중장기적인 균형 수준으로부터 얼마나 이탈해 있는지를 나타낸다. 이는 에이전트가 과도한 원화의 약세 또는 강세 국면을 인식하여 적응적인 헤지 전략을 수립하는 데 기여한다. 또한 국가 간 자본 유출입 압력과 한국 시장의 위험 프리미엄을 간접적으로 대리하기 위해 한·미 금리차(IR_Spread)를 관측 변수에 포함한다. 이는 한국과 미국의 장기 국채 수익률 차이로 정의되며, 거시적인 금융 환경의 변화를 모델에 반영하는 역할을 한다. 최종적으로 실제 시스템 구현 단계에서는 상기 기술한 네 가지 변수를 결합한 다변량 벡터 X 를 입력 특징(Input Feature)으로 사용한다. 이때 데이터의 연속성과 학습 추정의 안정성을 확보하기 위해 발생 가능한 결측값은 0으로 대체하는 전처리를 수행하였다.

4.3.2 국면 분류 모형

본 연구에서는 시장의 비관측 상태(Latent State)를 추론하고 현재의 변동성 환경을 정량적으로 정의하기 위해 Gaussian Hidden Markov Model (HMM)을 사용한다. 구현상 모형은 `hmmlearn` 라이브러리의 `GaussianHMM` 클래스를 활용하여 모델을 구현하였으며, 시장의 상태 수(K)를 3으로 설정하여 'Normal', 'Transition', 'Panic'의 세 가지 은닉 상태로 매핑하였다. 모형의 모수 추정은 최대우도추정(Maximum Likelihood Estimation, MLE)과 Expectation-Maximization (EM) 알고리즘을 통해 수행되며, 관측 데이터의 분포는 다변량 정규분포(Multivariate Normal Distribution)를 따르는 것으로 가정한다. 학습에는 전 기간의 일별 특징 벡터(X)를 사용하여 모형이 시장의 장기적인 전이 확률(Transition Probability)을 학습하도록 설계하였다. 학습이 완료된 후, 모형이 산출한 은닉 상태 시퀀스에 경제적 의미를 부여하기 위해 각 상태별로 대응되는 VIX 지수의 기대값을 산출한다. 상태 레이블링은 다음과 같이 정의된 상태별 VIX 수준을 기준으로 수행된다. 산출된 값을 크기순으로 정렬하여, 평균 변동성이 가장 낮은 상태를 'Normal', 중간 수준을 'Transition', 그리고 변동성이 극도로 높은 상태를 'Panic'으로 정의한다. 이러한 방식은 사전에 임의로 국면을 나누는 것이 아니라, 데이터에 내재된 변동성 구조에 기반하여 국면이 자동 결정(Data-driven)되도록 함으로써 모형의 객관성을 확보한다. 실시간 운용 시점(t)에서는 관측치에 대해 HMM이 예측한 현재 상태를 해당 국면 레이블로 변환하여 에이전트의 입력값으로 활용한다.

4.3.3 국면별 헤지 전략 및 Natural Hedge 반영

먼저 각 국면(S)에서의 시장 상관구조는 기초자산 수익률(r_e)과 외환 헤지 포지션에 해당하는 헤지자산 수익률(r_h) 간의 상관관계수(ρ)를 통해 정량화된다. 역사적 데이터 분석 결과에 따르면, Normal 국면에서는 주식과 환율 간의 강한 음(-)의 상관관계($\rho \approx -0.4$)가 관찰되며, 이는 주가 하락 시 환율이 상승하여 포트폴리오의 손실을 일부 상쇄하는 자연적인 분산 효과를 제공한다. 반면, Panic 국면으로

진입할수록 자산 간 동조화 현상이 심화되어 상관관계수가 0.5 에서 0.9 수준까지 급격히 상승하는 경향을 보인다. 이는 시장 충격 발생 시 자산 가격이 동시에 하락하여 기존의 내재적 분산 효과가 소멸됨을 의미한다. 이러한 상관구조의 변화를 반영하여 각 국면에서의 목표 헤지 강도(h^*)는 상관관계수에 대응하여 단조 증가하는 함수의 형태로 설계한다. 즉, 상관관계가 양(+)의 방향으로 강해질수록 내재적 방어력이 약화된 것으로 판단하여 보다 보수적인 헤지 비율을 적용한다. 국면별 세부 설계 원칙은 다음과 같다. 첫째, Normal 국면은 주식과 환율의 음의 상관관계에 의해 내재적 분산 효과가 원활히 작동하는 구간이다. 따라서 본 연구에서는 이 구간에서 100% 완전 헤지보다 낮은 비율의 부분 헤지를 허용함으로써 헤지 비용 및 가용자본(AC) 관리 측면의 우월성을 확보한다. 특히 구간에서는 약 70~80% 수준의 헤지 비중을 유지하여 과도한 오버헤지로 인한 기회비용 발생을 억제한다. 둘째, Transition 국면은 시장의 상관구조가 약화되거나 급격히 변동하는 과도기적 단계로 정의한다. 이 구간에서는 향후 변동성 확대 가능성에 대비하여 Normal 국면보다 한 단계 높은 헤지 강도를 유지한다. 상관관계수가 음(-)에서 양(+)으로 이동함에 따라 헤지 비율을 점진적으로 상향 조정하여, 자연 헤지 효과가 희석되는 지점에서 시스템의 방어력을 선제적으로 보완하도록 설계하였다. 셋째, Panic 국면은 상관관계수가 0.5 이상으로 급등하여 자산 간 동조화가 극대화되는 위기 상황이다. 이때는 내재적 분산 효과가 사실상 붕괴된 상태이므로, 포트폴리오 보호를 위해 80~100% 수준의 높은 헤지 비율을 기본 목표로 설정하였다. 이 과정에서 시장 국면뿐만 아니라 자본비율(K-ICS)의 건전성을 종합적으로 고려하여 규제 하한선을 준수하는 보수적인 방어 헤지를 수행하였다. 본 절에서는 HMM 국면과 상관관계수에 기반한 이론적·정성적 헤지 원칙을 제시하였다. 이러한 설계 원칙을 실제 운용 가능한 동적 전략으로 구체화하기 위해, 이어지는 4.4 절에서는 강화학습(PPO) 기반의 정책 결정 과정을 상술하고,

4.5 절에서는 임계값을 활용한 다단계 안전장치(Safety Layer)의 구현 방안을

기술한다.

4.4 강화학습 기반 의사결정 엔진(PPO)

본 연구에서는 단순한 환율 변동 예측의 한계를 극복하고, 규제 자본의 효율성을 극대화할 수 있는 최적의 동적 헤지 정책(Dynamic Hedging Policy)을 도출하기 위해 강화학습 알고리즘인 Proximal Policy Optimization(PPO)을 도입하였다. PPO 알고리즘은 정책 업데이트 시 급격한 변화를 제한함으로써 학습의 안정성과 우수한 수렴 성능을 보장하는 특성을 지닌다. 이러한 안정성은 보수적인 리스크 관리가 요구되는 금융 의사결정 모델에 있어 매우 중요한 요소로 작용한다. 본 모델의 구현 및 학습 환경 구축을 위해 최신 라이브러리를 활용하였다

4.4.1 학습 환경 설계

PPO 환경의 상태 공간은 시장 환경과 자본의 건전성을 동시에 반영할 수 있도록 네 가지의 연속형 변수로 구성하였다. 각 변수는 데이터의 범위를 제한하여 학습 효율을 높이기 위해 [0, 1] 사이의 값으로 정규화되었다. 첫째, 현재의 헤지 수준을 나타내는 현재 헤지 비율(h)을 상태 정보에 포함하여 에이전트가 이전의 의사결정 상태를 인지하도록 하였다. 둘째, 시장의 변동성을 반영하기 위해 정규화된 VIX 지수(VIX_norm)를 사용하며, 산식은 다음과 같다. 셋째, 자산 간의 연계 구조를 파악하기 위해 정규화된 주식-환율 상관관계수(ρ_norm)를 포함하였다. 이는 상관관계수의 범위(-1~1)를 선형 변환하여 반영한다. 마지막으로, 금융기관의 자본 적정성 지표인 정규화된 SCR 비율(SCR_norm)을

반영하여 자산 운용의 안정성을 도모하였다. 이러한 네 가지 상태는 각각 현재 헤지 수준, 시장 변동성·상관구조, 자본 적정성을 동시에 반영하며, Regime 분류기는 별도로 HMM에서 운용하되 VIX·상관계수 등을 통해 간접적으로 반영된다.

4.4.2 행동 공간 설계

본 모델에서 PPO 에이전트의 행동 공간은 $[-1, 1]$ 범위 내의 연속형 스칼라 값(a)으로 정의된다. 이는 에이전트가 매 시점 결정하는 헤지 비율의 변화량을 의미하며, 실제 운용 환경에 적용하기 위해 다음과 같은 선형 변환 및 클리핑(Clippping) 과정을 거쳐 차기 헤지 비율(h_{new})을 산출한다.

4.4.3 행동 정의(Action Space)

PPO 에이전트의 행동은 연속형 스칼라이며, 이를 헤지 비율 변화량으로 선형 변환한다. 위 식에서 알 수 있듯이, 한 번의 리밸런싱 시 허용되는 헤지 비율의 최대 변화 폭은 $10\%p$ 로 제한된다. 이러한 제약 조건은 급격한 포트폴리오 변경으로 인한 시장 충격과 거래 비용을 억제하는 역할을 하며, 클리핑 함수를 통해 최종 헤지 비율이 항상 유효 범위인 $[0, 1]$ 내에 존재하도록 보장한다.

4.4.4 보상 함수(Reward Function) 정의

강화학습 에이전트가 규제 자본의 효율성과 비용 최적화를 동시에 달성하도록 유도하기 위해, 보상 함수(R_t)는 K-ICS SCR 비율, 헤지 및 교체 매매 비용, 그리고 규제 위반 페널티를 통합하여 설계하였다. 전체 보상 산식은 다음과 같다. 여기서 $baseline_SCR$ 은 100% K-ICS 수준에 대응하는 기준값(약 0.10)이며, c_hedge 는 연 1.5%의 스왑포인트를 일할 계산한 일일 헤지 비용률(0.015)을⁷ 적용하였다. 또한 과도한 자산 교체 매매를 방지하기 위해 가중치 0.1을 부여한 페널티 항을 포함하였다. 특히, 규제 준수 여부에 따른 강력한 페널티 체계를 구축하여 안정성을 확보하였다. K-ICS 비율이 100% 미만인 경우에는 -1,000 점의 고정 페널티를 부과하여 해당 정책을 학습 과정에서 즉각 배제하도록 설계하였다. 아울러 100%에서 130% 사이의 구간에서도 $(130 - K-ICS)$ 에 비례하는 가변 페널티를 추가함으로써, 에이전트가 규제 하한선을 상회하는 충분한 자본 적정성을 유지하면서도 최적의 헤지 전략을 탐색하도록 유도하였다.

4.4.5 리밸런싱 제약 및 비용 최적화

실무적인 운용 제약 조건을 반영하기 위해 직전 시점 대비 헤지 비율의 변화량인 Δh 에 비례하는 페널티 항을 보상 함수에 명시적으로 포함하였다. 이는 강화학습 에이전트가 단기적인 변동성에 민감하게 반응하여 발생하는 불필요하고 잦은 리밸런싱을 억제하기 위함이다. 이러한 설계를 통해 자산 교체 매매에 따른 거래 비용을 최소화함과 동시에, 대규모 자산 운용 시 발생할 수 있는 시장 충격을 완화하여 전략의 실효성을 확보하였다.

4.4.6 학습 설정 및 정책 검증

PPO 에이전트의 학습은 모델의 수렴 안정성과 효율성을 고려한 하이퍼파라미터 설정을 바탕으로 수행되었다. 학습 과정에서는 콜백(Callback) 메커니즘을 활용하여 에피소드별 총 보상(Total Reward) 및

⁷ 모델 구현에는 Stable-Baselines3 라이브러리를 사용했으며, 모든 학습 과정은 Gymnasium과 호환되는 환경에서 수행되었다.

에피소드 길이의 추이를 실시간으로 모니터링함으로써 정책의 학습 곡선을 분석하였다. 또한 본 연구에서는 시장의 변동성이 급증하는 이례 현상에 대비하기 위해 VIX 지수가 특정 임계치를 초과하는 구간에서 별도의 '안전 계층(Safety Layer)' 개입 여부를 집계하는 전용 콜백을 운용하였다. 이는 학습된 정책이 단순히 과거⁸ 데이터에 과적합(Overfitting)되지 않고, 4.5 절에서 후술할 다단계 안전장치(Multistage Safeguard)와 유기적으로 결합하여 리스크를 통제할 수 있는지 검증하기 위한 절차이다.

4.5 다단계 안전 장치(Contingency Plan)

본 연구에서는 강화학습 에이전트의 오판을 제어하고 보험 규제(K-ICS) 준수를 보장하기 위해, 다단계 안전 장치를 적용한다. 이 안전 장치는 PPO가 제안한 헤지 비율 조정안을 입력으로 받아, VIX와 K-ICS 비율에 따라 강제적으로 수정된 최종 헤지 비율을 산출한다.




Figure 4. PPO 아키텍처

4.5.1 제 1 단계: 점진적 위험 감축

K-ICS 비율이 감독 당국의 권고 수준에는 부합하나 잠재적 위험이 존재하는 구간($100\% \leq \beta < 130\%$)에 진입할 경우, 적기시정조치 발동 가능성을 선제적으로 관리하기 위해 점진적 위험 감축 전략을 수행한다. 이 단계에서 시스템은 현재의 헤지 비율(h)을 기준으로 다음과 같은 산식에 따라 차기 헤지 비율(h_{new})을 결정한다. 즉, 매 시점 최대 10%p 씩 헤지 비중을 단계적으로 상향 조정하며, 위험 구간이 지속될 경우 최종적으로 헤지 비율이 1.0(100%)에 수렴하도록 유도한다. 특히 해당 구간에서는

⁸ PPO 알고리즘의 주요 하이퍼파라미터: total_timesteps=100,000, learning_rate=3e-4, n_steps=2,048, batch_size=64, $\gamma=0.99$.

강화학습 에이전트의 의사결정과 무관하게 헤지 비중의 축소가 엄격히 제한되며, 이는 자본 적정성 확보를 최우선으로 하는 보수적인 운용 원칙을 알고리즘적으로 구현한 것이다.

4.5.2 제 2 단계: 규제 준수 보장

K-ICS 비율이 100% 미만으로 하락하는 상황은 보험회사의 지급여력비율 하한선을 위반하는 심각한 규제 리스크 상황으로 간주한다. 본 단계에서는 강화학습 에이전트가 제안하는 모든 행동을 무시하고, 규제 대응을 최우선으로 하여 즉각적인 100% 헤지를 강제한다. 이러한 강제 조정은 규제 위반 상황이 해소될 때까지 지속되며, 이후의 의사결정 과정에서도 헤지 비율이 100% 미만으로 하락하지 않도록 엄격히 제한하여 시스템적인 리스크 노출을 원천적으로 차단한다.

4.5.3 제 3 단계: 변동성 기반 시장 안전 장치

시장 변동성을 나타내는 VIX 지수를 활용하여 유동성 위기 및 패닉 구간에 대응하는 안전 장치를 구축하였다. 이는 거시경제적 불안정성이 강화학습 모델의 예측 범위를 벗어날 경우를 대비한 장치이다. 첫째, VIX 기반 패닉 제어 단계에서는 VIX 지수가 임계값인 40 을 초과할 경우, 이를 시장의 심각한 유동성 위기로 판단하여 즉시 100% 헤지를 트리거한다($h=1$). 둘째, VIX 지수가 20 이상의 전환 구간에 진입할 경우, 에이전트가 헤지 비율을 축소하려는 행동을 제안하더라도 이를 수용하지 않고 최소한 현재의 헤지 수준을 유지하도록 상향 편향을 적용한다. 이는 시장 불확실성이 증대되는 구간에서 점진적인 방어 포지션을 유도하기 위함이다.

4.5.4 운용 제약 및 최종 실행

실제 자산 운용상의 안정성을 높이기 위해 최종적인 헤지 비율 산출 과정에서 거래 단위 및 범위에 대한 제약 조건을 적용한다. 1 회 리밸런싱 시 허용되는 최대 변동 폭은 로 제한되어, 강화학습 에이전트가 극단적인 포지션 전환을 제안하더라도 실제 실행 단계에서는 15%p 이내의 점진적인 이동만이 허용된다. 최종 산출된 헤지 비율은 범위 내에서 클리핑(Clipping) 처리된다. 결과적으로 PPO 에이전트는 자본 효율성을 극대화하는 정책을 학습함과 동시에, 상기 명시된 다단계 안전 장치와 운용 제약에 의해 규제 위반과 극단적 레버리지 위험으로부터 구조적으로 보호된 범위 내에서만 실제 정책을 운용하게 된다.

4.6 K-ICS 대리 모델(Surrogate Model)

K-ICS 표준모형은 정밀한 건전성 산출이 가능하나, 복잡한 연산 과정으로 인해 방대한 에피소드를 반복 학습해야 하는 강화학습이나 실시간 의사결정 체계에 직접 통합하기에는 연산 비용이 과도하다는 한계가 있다. 이를 극복하고 효율적인 학습 환경을 조성하기 위해, 본 연구에서는 표준모형의 산출 결과를 높은 정확도로 근사하는 심층 신경망 기반의 대리 모델(Deep Neural Surrogate)을 구축하였다.

4.6.1 모델 구조 및 입력 변수

본 대리 모델은 시장 상황과 전략적 선택을 동시에 반영할 수 있도록 설계되었다. 모델의 입력 특징량(Input Features)은 현재의 헤지 비율(h)과 주식-환율 상관계수(ρ)의 2 차원 벡터로 구성되며, 출력값은 이를 바탕으로 예측된 정규화된 K-ICS SCR 비율(SCR_pred)이다.

4.6.2 네트워크 아키텍처 및 학습 설정

본 연구에서 구축한 대리 모델은 데이터 내에 존재하는 복잡한 비선형적 관계를 정교하게 학습하기 위해 총 5 개의 은닉층을 포함한 다층 퍼셉트론(MLP) 구조를 채택하였다. 모델의 입력 특징량은 헤지 비율(h)과 주식·환율 상관관계수(ρ)를 포함하는 2 차원 벡터로 구성되며, 최종 출력값은 이를 바탕으로 예측 및 정규화된 K-ICS SCR 비율이다. 네트워크의 층별 노드 수는 입력층으로부터 출력층에 이르기까지 512, 256, 128, 64, 32 개로 단계적으로 축소되도록 설계하여 고차원의 특징을 유의미한 수치로 압축하여 도출하도록 하였다. 모델의 안정적인 학습과 일반화 성능 확보를 위해 각 은닉층에는 ELU(Exponential Linear Unit) 활성화 함수를 적용하여 기울기 소실 문제를 방지하고 비선형 근사의 유연성을 극대화하였다. 또한 특정 노드에 대한 과도한 의존을 방지하고 과적합 리스크를 최소화하기 위해 각 은닉층에 0.2 의 드롭아웃(Dropout) 비율을 설정하였다. 모델의 가중치 최적화에는 Adam 옵티마이저를 사용하였으며, 학습률은 $5e-4$ 로 지정하여 정밀한 수렴을 도모하였다. 이러한 구조적 설계를 통해 대리 모델은 표준모형의 산출 결과를 신속하고 정확하게 모사하며 강화학습 에이전트에 즉각적인 피드백을 제공하는 기반이 된다.

4.6.3 데이터셋 구성 및 데이터 누수 방지 설계

본 대리 모델의 학습을 위한 데이터셋은 일별 시장 데이터에서 추출된 주식환율 상관관계수(ρ_t)를 고정시킨 상태에서 헤지 비율(h)의 범위를 촘촘하게 세분화하여 각 조합에 대응하는 SCR 비율을 산출하는 방식으로 구성되었다. 이러한 과정을 통해 (h_t) 쌍에 따른 SCR 의 변화를 정밀하게 포착할 수 있는 학습 샘플을 확보하였다. 특히 모델이 높은 SCR 구간에서의 변동성을 충분히 학습하고 테스트 구간에서 발생할 수 있는 상관관계수의 범위를 포괄할 수 있도록 높은 SCR 을 유발하는 데이터 조합에 대해 오버샘플링(Oversampling)을 실시하였다. 또한 테스트 데이터에서 식별된 극단적 상관관계수 구간에 대해서는 추가적인 샘플을 생성하여 투입함으로써, 모델이 이례적인 시장 상황에서도 견고한 예측 성능을 유지할 수 있도록 보완하였다. 데이터 분할 시에는 시계열 데이터의 특성을 고려하여 시간 순서를 엄격히 유지한 상태에서 학습 데이터(80%)와 검증 데이터(20%)로 분리하였으며, 모델의 최종 일반화 성능을 평가하기 위해 학습 과정에서 완전히 배제된 별도의 테스트 데이터셋을 구축하였다. 아울러 데이터 누수(Data Leakage)를 원천적으로 차단하기 위해 입출력 변수의 스케일링(Scaling) 과정에서 오직 학습 데이터셋의 통계량만을 활용하여 적합시키는 Anti-Leakage 원칙을 준수함으로써 모델의 신뢰성을 확보하였다.

4.7 설명 가능 AI(XAI) 구현 및 분석 체계

본 연구에서 구축한 강화학습 기반 시스템 전략의 의사결정 과정을 감독 기구나 리스크 관리 부서에 투명하게 소명하기 위해 설명 가능 AI(Explainable AI, XAI) 분석 체계를 구축하였다. 이는 PPO 에이전트가 제안하는 헤지 비율이 어떠한 논리적 근거를 바탕으로 산출되었는지 정량적으로 입증하기 위함이다. 구체적으로는 K-ICS 표준모형 엔진을 활용하여 헤지 비율(h)과 자산 간 상관관계수(ρ)의 변화가 실제 SCR 비율 및 순효율에 미치는 영향력을 평가하고 이를 시각화하여 분석하였다. 분석의 기초가 되는 자본 건전성 지표는 자산(A)과 부채(L)의 차이로 정의되는 가용자본을 요구자본으로 나누어 산출한다⁹. 이때 리스크 요인은 주식 리스크(SCR_e), 환율 리스크(SCR_fx), 금리 리스크(SCR_i)로 구분되며, 시장 리스크(SCR_mkt)는 주식과 환율 간의 상관관계수(ρ)를 반영하여 다음과 같이 정의된다. 최종적인 총 요구자본(SCR)은 상기 산식으로 도출된 시장 리스크에 금리 리스크(SCR_i)를 단순 합산하여 계산된다. 따라서 K-ICS 비율은 가용자본(AC)을 시장 리스크와 금리 리스크의 합으로 나누

⁹ 요구자본 산출 시 주식·환율 리스크 간 상호작용은 표준모형의 상관관계수 통합 방식을 따르며, 금리 리스크는 분산효과 없이 보수적으로 합산했다.

수치로 결정된다. 본 모델에서 핵심 변수인 헤지 비율(h)은 환율 리스크 요인에 직접적으로 관여한다. 환헤지를 실시할 경우 실질적인 환율 리스크는 $SCR_{fx}(1-h)$ 로 감소하며, 이를 시장 리스크 산식에 반영하면 헤지 수준과 상관계수를 변수로 하는 최종 K-ICS 비율 함수를 다음과 같이 도출할 수 있다. 결과적으로 K-ICS 비율은 환헤지 수준과 시장의 상관구조에 따라 비선형적으로 변화하는 구조를 갖는다. 이러한 수리적 모형을 바탕으로 XAI 분석을 수행함으로써, 에이전트가 특정 시장 상황(예: 상관계수 급증 시)에서 헤지 비율을 상향하거나 하향하는 결정이 실제 자본 적정성 지표에 어떠한 기여를 하는지 명확히 설명할 수 있는 근거를 마련하였다. 또한 본 시스템이 단순히 리스크를 최소화하는 것을 넘어 경제적 효율성을 동시에 달성하도록 유도하기 위해, 헤지 비용을 고려한 순효용(Net Utility) 함수를 정의하였다. 먼저 연간 헤지 비용(C_h)은 헤지 비율에 비례하여 발생하는 것으로 가정하며, 일일 단위의 비용을 연간으로 환산하여 다음과 같이 산출한다. 산출하였다. 여기서 연간 약 0.2% 수준의 헤지 비용을 적용하였다. 이를 바탕으로 도출된 순효용 함수(U)는 리스크 지표인 SCR 과 헤지 비용의 합을 최소화하는 것을 목표로 하며, 다음과 같이 정의된다. 이 함수를 통해 에이전트는 더 낮은 SCR(더 높은 안전성)과 더 낮은 운용 비용을 동시에 추구하는 최적의 균형점을 탐색하게 된다. 연구진은 각 상관계수 구간(Regime)별로 다수의 조합을 샘플링하여 순효용이 최대화되는 국면별 최적 헤지 비율을 분석하였다. 분석 결과, 음의 상관관계가 나타나는 정상 국면(Normal Regime)에서는 100% 완전 헤지보다 약 70~80% 수준의 부분 헤지가 SCR 관리와 비용 절감 측면에서 모두 우월하다는 점을 확인하였다. 반면, 상관계수가 0.7 수준으로 급증하는 패닉 국면(Panic Regime)에서는 100%에 근접한 높은 헤지 전략이 최적의 선택임을 정량적으로 도출하였다.

5. 실증 분석 및 결과

5.1 데이터 및 실험 환경 설정

본 연구의 모델 학습 및 검증을 위해 FnGuide 에서 추출한 과거 13 년(학습용 10 년, 검증 및 테스트용 3 년)의 일별 시장 데이터를 활용하였다. 전체 데이터셋은 시계열의 선후 관계를 유지하며 분할하였으며, 시뮬레이션 과정에서의 데이터 누수(Data Leakage)를 엄격히 방지하기 위해 성과 평가 및 백테스트는 학습에 사용되지 않은 완전히 분리된 테스트 구간만을 대상으로 수행하였다. 구체적인 기초 자산 데이터(Raw Market Data)의 구성은 다음과 같다: Global/FX: 미국채 10 년물 금리, S&P 500 지수, 원/달러 환율(Spot), 1M NDF 스왑포인트, VIX 지수, 한국 CDS 프리미엄(5Y). Domestic: KOSPI 200 지수, 국고채 10 년물 금리. 또한 시장 국면 인식(Regime Detection)의 정밀도를 제고하기 위해 다음과 같은 파생 변수(Derived Features)를 생성하여 모델의 입력값으로 활용하였다: Yield Spread: 국고채 10Y 와 미국채 10Y 의 차이로 한·미 금리 역전 국면 포착. FX MA Divergence: 환율의 20 일 이동평균 괴리율을 통한 급변 추세 탐지. VIX Change: 전일 대비 VIX 지수의 변화율로 공포 국면 진입 신호 감지. 또한 모델의 강건성(Robustness)을 검증하기 위해 정상 국면 외에 총 12 종의 스트레스 시나리오를 구축하였다. 특히 강화학습 에이전트가 학습 과정에서 경험하지 못한 극한 상황에 대응할 수 있도록 다음과 같은 합성 데이터와 위기 시나리오를 포함하였다.

5.2 평가 지표 정의

보험사의 자본 관리 효율성을 정량화하기 위해 본 연구는 'Modified Sharpe Ratio for Capital Efficiency'를 핵심 지표로 정의한다. 이는 전액 헤지(100% Hedge) 전략 대비 요구자본(SCR) 절감액을 투입된 추가 비용(또는 절감 비용)으로 나눈 값으로, 자본 절감 단위당 경제적 효율성을 나타낸다. 이와 함께 순편익(Net Benefit), 최저 K-ICS 비율, SCR 변동성 등을 종합 지표로 활용하였다.

5.3 전략별 성과 비교 (전 시나리오 평균, 테스트 구간)

Table 2. 전략별 성과 비교표 (전 시나리오 평균, 테스트 구간)

전략	RCR	Net Benefit
100% Hedge	0.00	-0.60 억
80% Fixed	0.25	-0.36 억
Rule-based	0.65	-0.11 억
자체 모델	2.26	+0.08 억




Figure 5. 전략별 자본 효율성 및 순편익 비교

자체 시스템은 Modified Sharpe Ratio 기준으로 가장 우수하며, Net Benefit 역시 유일하게 양수인 +0.08 억을 기록하여 비용 및 손실 관리 측면에서 압도적 우위를 보였다. 평가 기간 내 최저 K-ICS 비율은 1,248.7%를 유지하여 규제 안전성을 확인하였다.

5.4 시나리오별 성과

5.4 시나리오별 성과




Figure 6. 시나리오별 성과

실증 분석 결과, 본 연구에서 제안한 자체 모델은 총 12 종의 시나리오 중 8 개 시나리오에서 자본 효율성 지표(ROR)를 포함한 주요 성과 지표 기준 최고 효율을 기록하며 기존 전략 대비 뚜렷한 우위를 확인하였다. 특히 상관관계 역전(Correlation Reversal), 금리 급등(Rate Surge), 그리고 변동성 지속(VIX Sustained High)과 같은 3 개 극단적 위기 시나리오에서는 시스템 내 설계된 다단계 안전장치(Contingency Plan)가 의도한 대로 정교하게 작동하는 것을 확인하였다. 해당 국면에서 모델은 자본 가치 보전을 위해 즉각적으로 100% 헤지 비율로 전환되었으며, 이를 통해 보수적이고 안정적인 의사결정 체계를 입증하였다.

5.5 COVID-19 위기 구간

Table 3. COVID-19 위기 구간 K-ICS 비교표

전략	최저 K-ICS	안전 마진
100% Hedge	1,449.6%	11.6 배
80% Fixed	1,159.5%	9.8 배
자체 모델	1,248.7%	10.5 배

자체 모델은 위기 구간에서도 K-ICS 를 100% 이상으로 유지하며, VIX 급등 시 Emergency De-risking 이 정상 작동함을 확인하였다.




Figure 7. COVID-19 위기 비교

5.6 Efficient Frontier (위험 vs 비용)

Table 4. Efficient Frontier 비교표

전략	Risk (SCR)	Cost (연간)	비고
100% Hedge	11.85%	1.5%	비효율 영역
80% Fixed	11.39%	1.2%	비효율 영역
자체 모델	9.88%	0.21%	Sweet Spot

본 모델은 표준모형 하에서도 헤지 비용을 약 86% 절감(0.21% vs 1.5%)하여 가용자본을 효과적으로 보전한다. 이는 내부모형 도입 전이라도 즉각적인 재무적 이득을 제공할 수 있음을 의미한다. 동시에, 실제 시장의 상관관계 변화를 반영할 수 있는 내부모형 제도 안착 시, 요구자본(SCR) 자체를 전액 헤지 대비 최대 10.38%까지 낮추는 이종의 자본 효율성을 달성할 수 있음을 시사한다.




Figure 8. 자본 규제 하의 효율적 경계면

5.7 핵심 지표 요약

Table 5. 핵심 지표 요약표

카테고리	지표	결과
Surrogate	MAPE	0.05%
RL	Avg Reward	13.24
규제 준수	최저 K-ICS	1,248.7%
위험	SCR	9.88%
비용	Hedge Cost	0.21%
자본 절감	포트폴리오 최적화	최대 10.38%
위기 대응	COVID-19 Min K-ICS	1,248.7%

6. 결론

6.1 연구 요약

본 연구는 신지급여력제도(K-ICS) 환경 하에서 보험사의 환위험 관리를 '단순 가격 예측'이 아닌 '시장 국면 인식 및 자본 효율성 최적화'의 관점으로 재정의하고, 이를 실현하기 위한 동적 의사결정 시스템을 제안하였다. 주요 연구 결과 및 기여도는 다음과 같다. 자본상쇄(Portfolio Optimization) 효과의 실증: K-ICS의 요구자본(SCR) 산식 내 상관관계를 분석하여, 주식과 외환 리스크 간의 자연 헤지(Natural Hedge)가 발생하는 국면에서는 부분 헤지가 100% 전액 헤지보다 위험액과 비용을 동시에 절감할 수 있음을 수리적으로 입증하였다. 통합 지능형 아키텍처 구축: 시장 국면을 분류하는 HMM, 최적 정책을 도출하는 PPO, 규제 준수를 강제하는 Contingency Plan, 연산 효율화를 위한 K-ICS Surrogate 모델, 그리고 의사결정 근거를 제시하는 XAI 모듈을 유기적으로 결합하였다. 실증적 우월성 확인: 12종의

스트레스 시나리오 및 COVID-19 위기 구간 분석 결과, 제안 시스템은 기존 전략 대비 우수한 Modified Sharpe Ratio for Capital Efficiency 와 Net Benefit 성과를 거두었으며, 극단적 위기 시나리오에서도 보수적 모드로 즉각 전환되는 강건성을 보였다.

6.2 연구의 한계점

본 연구는 실무적 적용 가능성을 높였으나, 다음과 같은 학술적·기술적 한계를 지닌다. 데이터 및 환경 의존성: 분석에 사용된 데이터 기간, 자산 구성, 금리 및 환율 가정이 특정 환경에 국한되어 있어, 다른 시장 상황이나 상이한 규제 환경으로의 일반화를 위해서는 추가적인 검증이 필요하다. 실거래 제약 사항: 보상 함수 내 Turnover Penalty 를 통해 거래 비용과 슬리피지를 일부 반영하였으나, 실제 운용 현장에서의 실시간 데이터 연동 문제나 유동성 제약, 엄밀한 수수료 체계 및 시장 충격 비용에 대한 추정은 보완이 요구된다. 하이퍼파라미터 민감도: HMM 의 최적 상태 수 선정, PPO 알고리즘의 학습 하이퍼파라미터, Contingency Plan 의 임계값 설정 등에 대한 포괄적인 민감도 분석은 별도의 연구 과제로 남아 있다.

6.3 규제 적용 및 정책적 시사점

현재 국내 보험업계의 내부모형(Internal Model) 신청 사례가 전무한 현실을 고려할 때, 본 시스템의 실무적 효익은 단계적으로 발현될 것으로 기대된다. 표준모형 하의 실질적 비용 최적화 (단기적 효익): 현행 K-ICS 표준모형은 주식-외환 상관계수를 -0.25 로 고정하고 있어, AI 가 포착한 실제 시장의 음의 상관관계를 통한 요구자본(SCR) 절감 효과가 즉각적으로 인정되지 않을 수 있다. 그러나 본 연구의 프레임워크는 시장 국면에 따른 최적 헤지 비중 결정을 통해 불필요한 100% 헤지 관행에서 벗어나 연간 약 86% 수준의 헤지 비용(0.21% vs 1.5%)을 절감한다. 이는 규제 산식의 변경 없이도 보험사의 가용자본(AC)을 직접적으로 보전하여 지급여력비율을 제고하는 핵심적인 재무 관리 도구로 즉각 활용될 수 있다. 내부모형 도입의 당위성 및 확장성 (장기적 효익): 2026 년 도입 예정인 내부모형 제도 하에서는 보험사 고유의 리스크 특성과 동적인 시장 국면을 반영할 수 있게 된다. 본 연구의 시스템은 내부모형 승인 시 실제 시장의 음의 상관관계를 리스크 측정에 직접 반영함으로써, 요구자본(SCR) 자체를 최대 10.38%까지 낮추는 이중의 자본 효율성을 달성할 수 있는 선제적 관리 인프라로서 가치를 지닌다. 정책적 시사점: 규제 당국 측면에서 본 시스템은 '블랙박스'인 AI 의 의사결정 논리를 XAI(SHAP)를 통해 시각화하고, 극단적 위기 시 Contingency Plan 이 즉각 작동하도록 설계되어 금융 실무 현장에서 요구되는 모델의 신뢰성 및 안전성 검증 기준을 충족한다. 이는 향후 인공지능 기반 리스크 관리 모델의 내부모형 승인을 위한 기술적 가이드라인 제시에 기여할 수 있다.

6.4 향후 연구 방향

본 연구를 고도화하기 위한 향후 연구 방향은 다음과 같다. 실시간 의사결정 시스템화: Bloomberg 나 Reuters 등 실시간 데이터 피드를 연동하여 일일 또는 장중 의사결정이 가능한 엔드투엔드(End-to-End) 파이프라인을 구축할 필요가 있다. 모델의 확장 및 심화: 더 장기적인 시계열(500,000 timesteps 이상) 학습을 수행하고, 2015 년 중국발 증시 폭락이나 2022 년 금리 쇼크 등 추가 시나리오를 반영하여 퀀타일 회귀(Quantile Regression) 기반의 꼬리 위험(Tail Risk) 대응 능력을 강화해야 한다. 도메인 및 자산군 확장: 단일 통화 헤지를 넘어 다중 통화(Multi-currency) 환경으로 확장하고, 다른 자산 클래스와의 통합 및 부채 측면을 고려한 ALM(자산부채관리) 통합 최적화 모델로의 발전이 가능하다.

6. 참고문헌

1. 금융감독원 (2023). 지급여력제도(K-ICS) 주요 내용 및 해설서. 금융감독원 지급여력제도실.
2. 김수은, 유재필, & 박병욱. (2024). 경제 시계열 데이터의 확장을 위한 TimeGAN. *Asia-pacific Journal of Convergent Research Interchange*, 10(7), 209-220.
3. 노건엽, 김세환, & 이승주. (2024). K-ICS 영향분석과 보험회사 대응방안. 연구보고서 2024-14. 보험연구원.
4. 임준환 (2023.11). 국내 생명보험회사의 환헤지 행태 및 환헤지규제. KIF Working Paper 2023-10. 한국금융연구원.
5. 장근혁 (2023). 한미금리 역전에 따른 환헤지 비용의 증가와 시사점. 자본시장포커스. 자본시장연구원.
6. 한화생명 (2025). 2025 한화생명 지속가능경영보고서: Green Life for Sustainable Tomorrow.
7. Hounwanou, C. D., Gaba, Y. U., & Ntakirutimana, P. (2025). Evaluating generative models for synthetic financial data Trinh, V. A Comprehensive Review: Applicability of Deep Neural Networks in Business Decision Making and Market Prediction Investment. *arXiv preprint arXiv:2502.00151v1*.
8. Ryou, H. S., Kim, S. H., Lee, H. S., & Oh, K. J. (2026). A multi-path time-series generation and prediction model for financial markets using discriminator-filtered Monte Carlo TimeGAN. *Applied Soft Computing*, 186, 114106.
9. 「보험회사 신지급여력제도(K-ICS) 개요」, 관련 연도.
10. EIOPA, “Solvency II Delegated Regulation”, 2015.
11. Hamilton, J.D., “A new approach to the economic analysis of nonstationary time series and the business cycle,” *Econometrica*, 1989.
12. Schulman, J. et al., “Proximal Policy Optimization Algorithms,” *arXiv:1707.06347*, 2017.
13. Lundberg, S.M. & Lee, S.I., “A Unified Approach to Interpreting Model Predictions,” *NeurIPS*, 2017.